



TP3 - Perceptrón Simple y Multicapa

Grupo 1
Santiago José Hirsch
Matías Ignacio Luchetti
Santiago Tomás Medin
Mariano Agopian




Ejercicio 1

Perceptrón Simple

Parámetros


- Learning rate = 0.1
- Epochs = 200
- Epsilon = 0
- Función de activación = STEP



Problema AND

Parámetros

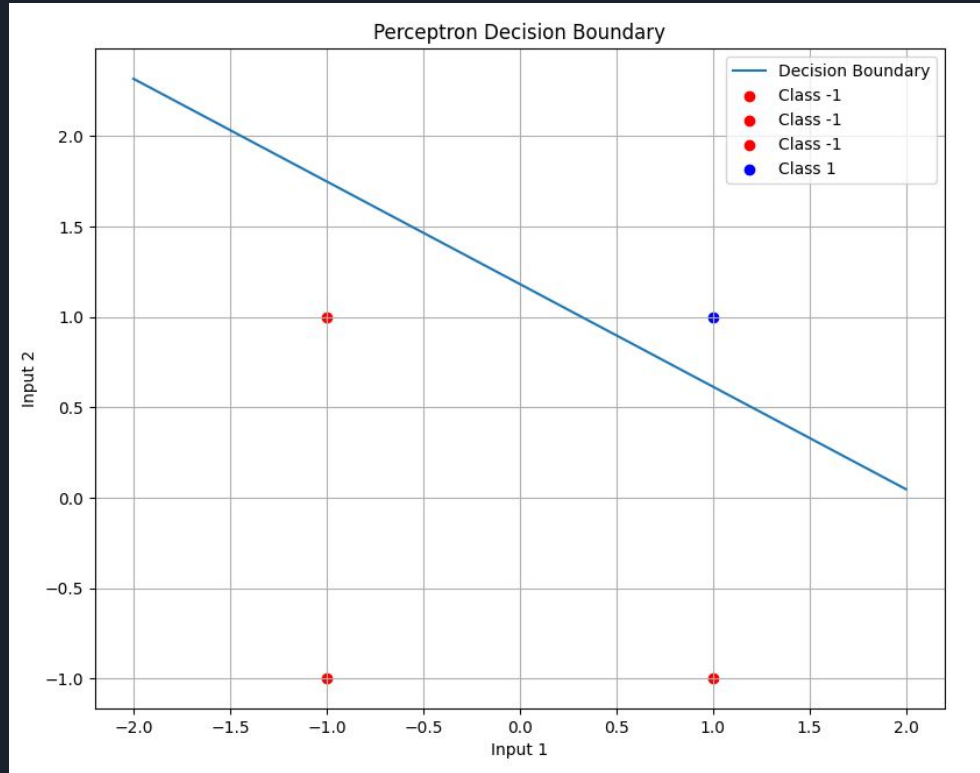
- Learning rate = 0.1
- Epochs = 200
- Epsilon = 0
- Función de activación = STEP



Decisión

Parámetros

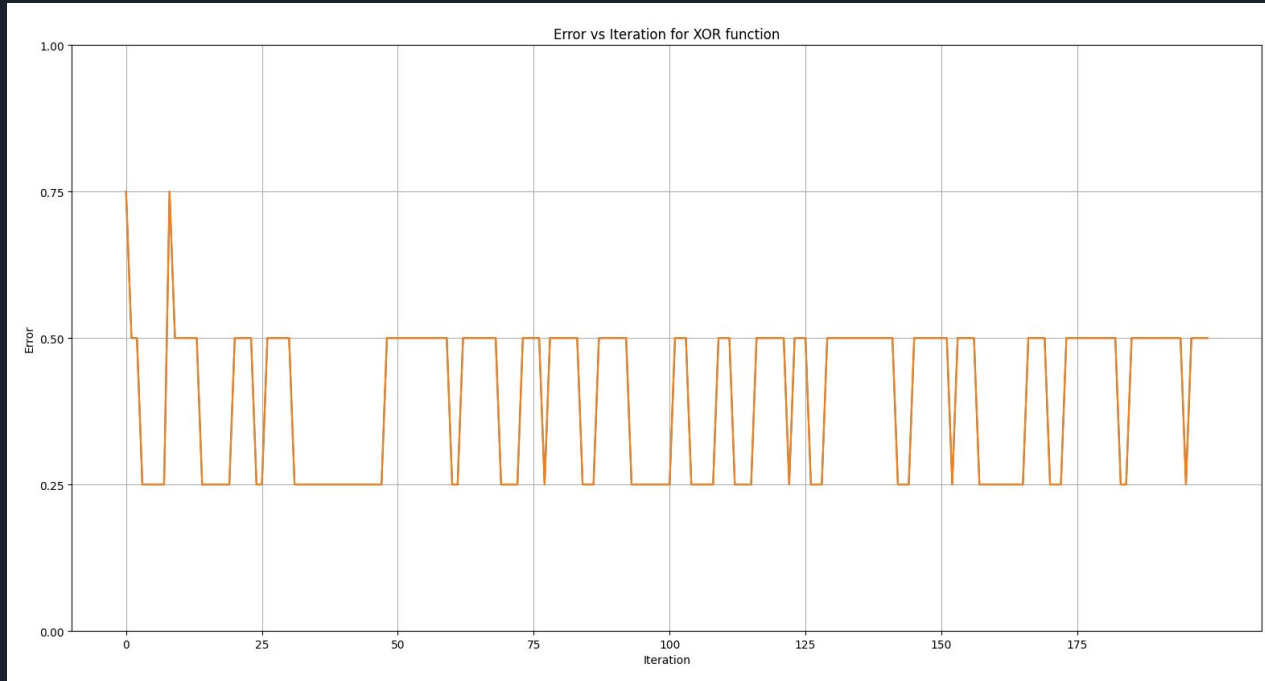
- Learning rate = 0.1
- Epochs = 200
- Epsilon = 0
- Función de activación = STEP



Problema XOR

Parámetros


- Learning rate = 0.1
- Epochs = 200
- Epsilon = 0
- Función de activación = STEP



Decisión

Parámetros

- Learning rate = 0.1
- Epochs = 200
- Epsilon = 0
- Función de activación = STEP





Ejercicio 2



Lineal o no lineal, esa es la cuestión


Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0
- Funcion de activacion (IDENTIDAD, SIGMOIDE, TANH)
- Beta = 1
- 100% training

Lineal o no lineal

Parámetros:

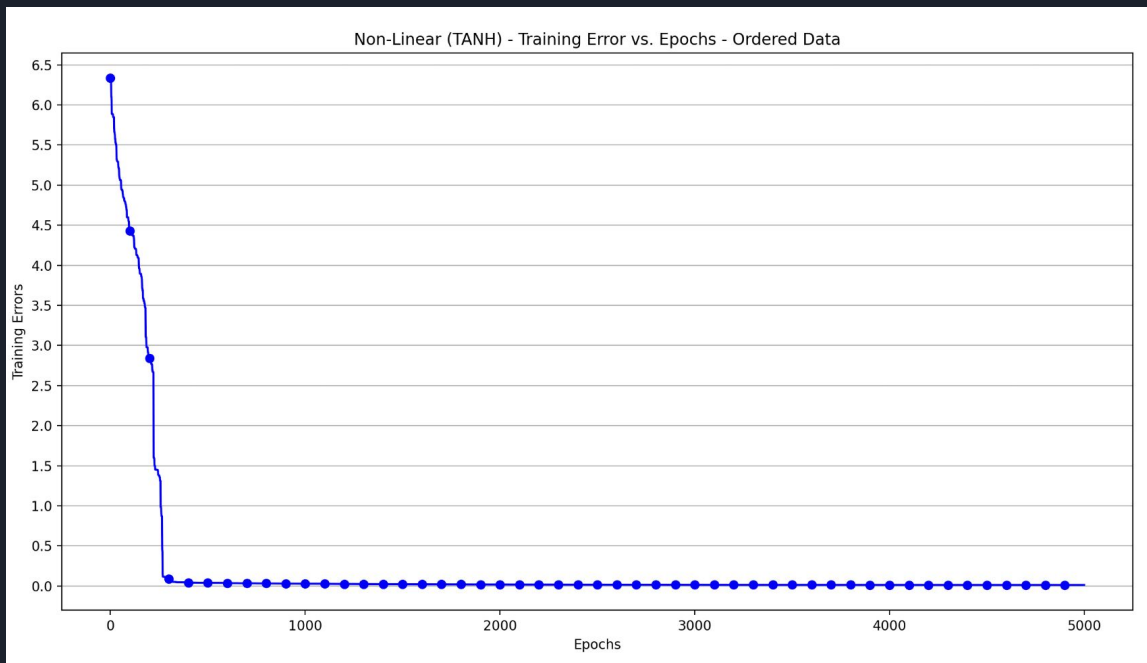
- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0
- Funcion de activacion (IDENTIDAD, SIGMOIDE, TANH)
- Beta = 1
- 100% training



Lineal o no lineal

Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0
- Funcion de activacion (IDENTIDAD, SIGMOIDE, TANH)
- Beta = 1
- 100% training




Mínimo: 0.0136

Lineal o no lineal

Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0
- Funcion de activacion (IDENTIDAD, SIGMOIDE, TANH)
- Beta = 1
- 100% training




Mínimo: 0.00376

Lineal o no lineal - Función SIGMOIDE

$$\theta(h) = \frac{1}{1 + \exp^{-2\beta h}}$$

$$\theta'(h) = 2\beta\theta(h)(1 - \theta(h))$$





Datos ordenados vs datos mezclados

Parámetros:


- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0.01
- Función de activación = sigmoide (datos interpolados entre 0 y 1)
- K-Fold (k entre 2 y 5)
- Beta = 1

Datos ordenados vs datos mezclados


Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0.01
- Función de activación = sigmoide
- K-Fold (k entre 2 y 5)
- Beta = 1

SIGMOID - Test Error vs. K - Shuffled Data - K=2



SIGMOID - Test Error vs. K - Ordered Data - K=2




Datos ordenados vs datos mezclados


Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0.01
- Función de activación = sigmoide
- K-Fold (k entre 2 y 5)
- Beta = 1

SIGMOID - Test Error vs. K - Shuffled Data - K=3



SIGMOID - Test Error vs. K - Ordered Data - K=3




Datos ordenados vs datos mezclados


Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0.01
- Función de activación = sigmoide
- K-Fold (k entre 2 y 5)
- Beta = 1

SIGMOID - Test Error vs. K - Shuffled Data - K=4



SIGMOID - Test Error vs. K - Ordered Data - K=4




Datos ordenados vs datos mezclados


Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0.01
- Función de activación = sigmoide
- K-Fold (k entre 2 y 5)
- Beta = 1

SIGMOID - Test Error vs. K - Shuffled Data - K=5




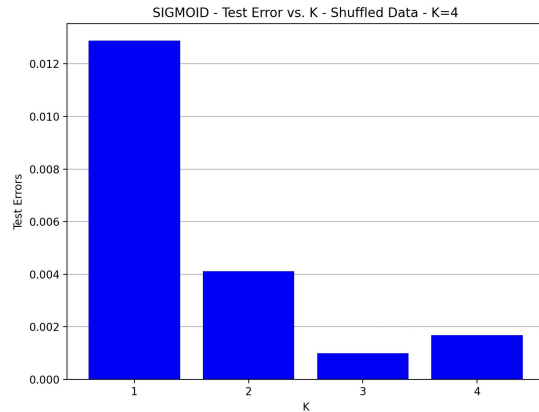
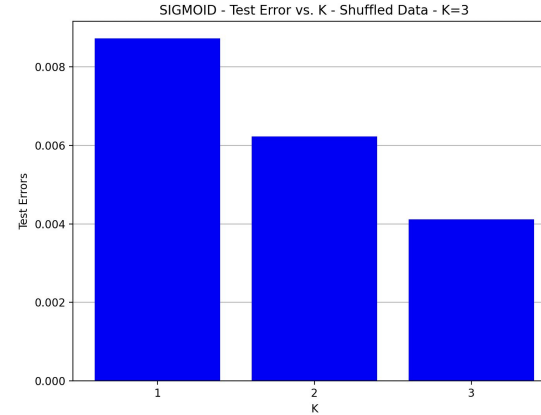
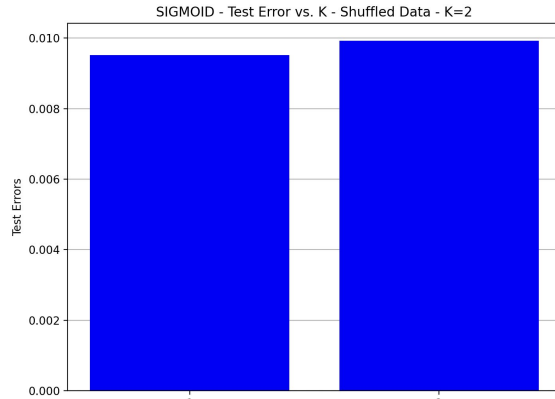
SIGMOID - Test Error vs. K - Ordered Data - K=5



Datos ordenados vs datos mezclados

Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 5000
- Epsilon = 0.01
- Función de activación = sigmoide
- K-Fold (k entre 2 y 5)
- Beta = 1





Errores en función de las épocas

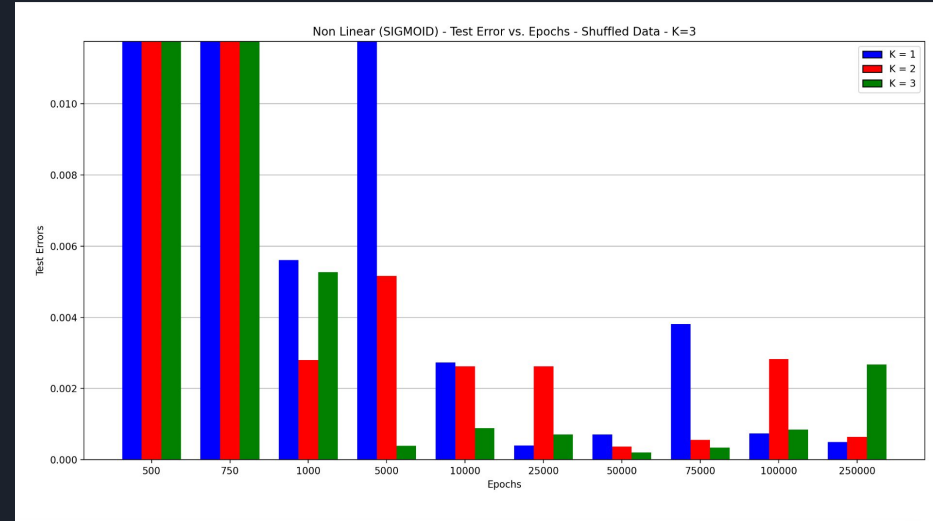
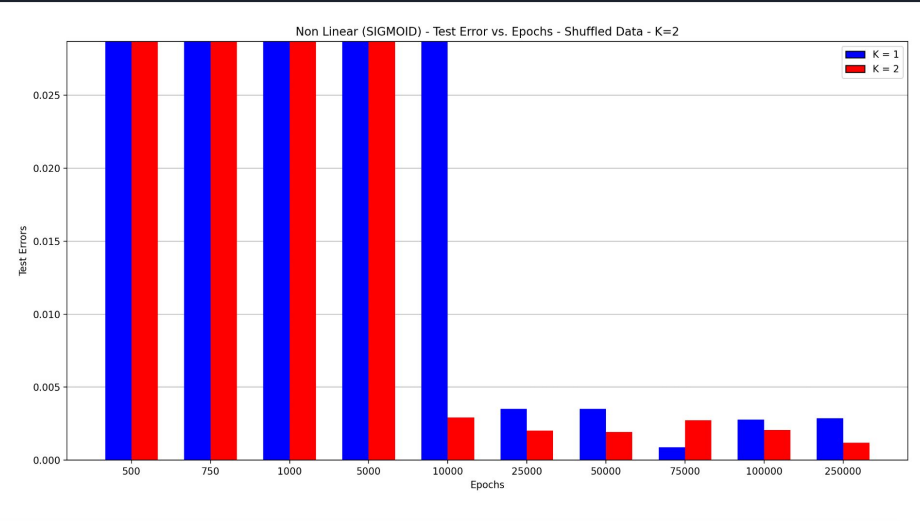
Parámetros:

- Learning rate = 0.01
- Online
- Epochs (500, 750, 1000, 5000, 10000, 25000, 50000, 75000, 100000, 250000)
- Epsilon = 0
- Función de activación = sigmoide (datos interpolados entre 0 y 1)
- K-Fold (k entre 2 y 5)
- Beta = 1

Errores en función de las épocas

Parámetros:

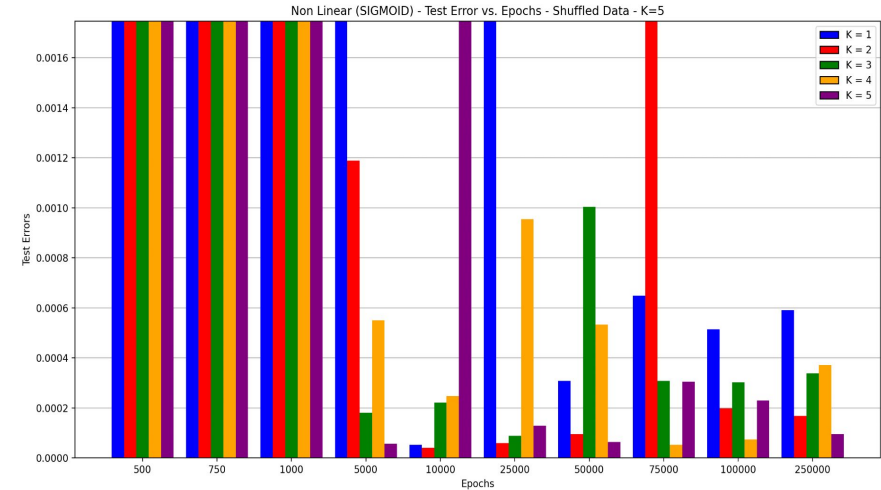

- Learning rate = 0.01
- Online
- Epsilon = 0
- Función de activación = sigmoide
- K-Fold (k entre 2 y 5)
- Beta = 1



Errores en función de las épocas

Parámetros:


- Learning rate = 0.01
- Online
- Epsilon = 0
- Función de activación = sigmoide
- K-Fold (k entre 2 y 5)
- Beta = 1



Errores en función de las épocas

Parámetros:

- Learning rate = 0.01
- Online
- Epsilon = 0
- Función de activación = sigmoide
- K-Fold (k entre 2 y 5)
- Beta = 1



Error promedio para 100000
épocas = 2.0352×10^{-4}

Error promedio para 250000
épocas = 1.5629×10^{-3}



Elección mejor beta

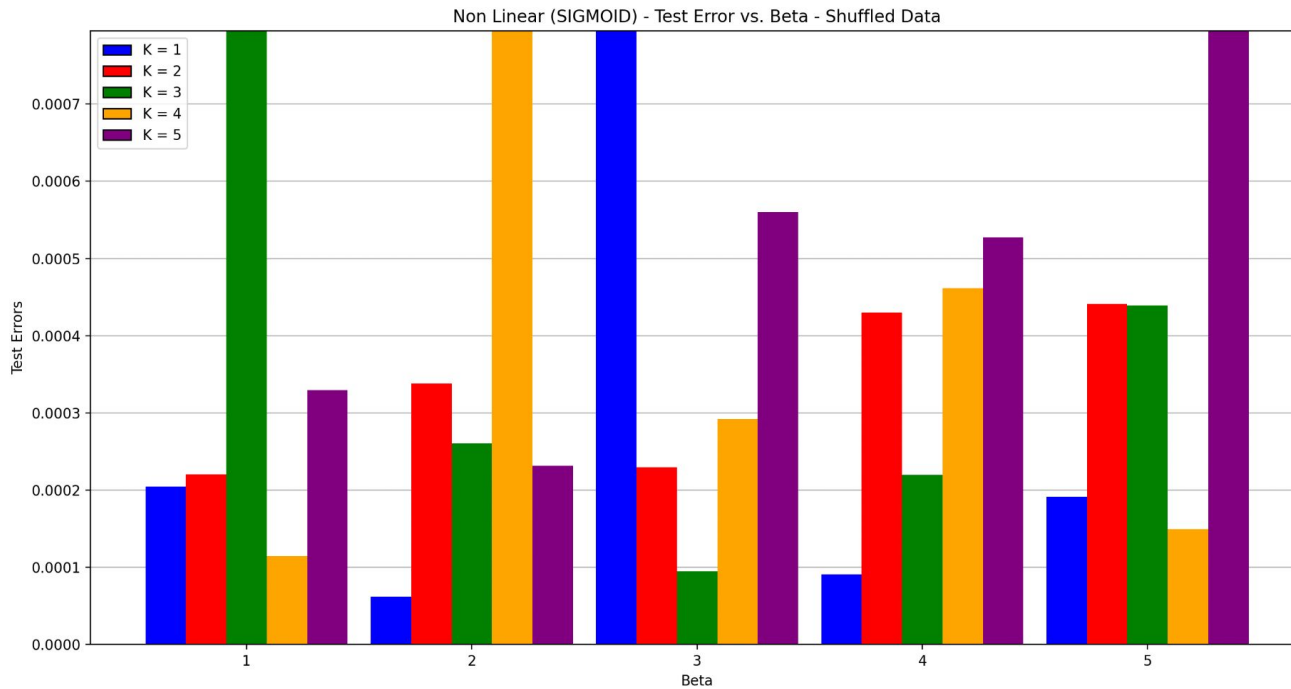
Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 100000
- Epsilon = 0
- Función de activación = sigmoide (datos interpolados entre 0 y 1)
- K-Fold: $k = 5$
- Beta (1, 2, 3, 4, 5)

Elección mejor beta

Parámetros:

- Learning rate = 0.01
- Online
- Epochs = 100000
- Epsilon = 0
- Función de activación = sigmoide
- K-Fold: k = 5
- Beta (1, 2, 3, 4, 5)





Elección mejor beta - Resultado

Beta = 4

$$\theta(h) = \frac{1}{1 + \exp^{-2\beta h}}$$

$$\theta'(h) = 2\beta\theta(h)(1 - \theta(h))$$





Elección mejor learning rate

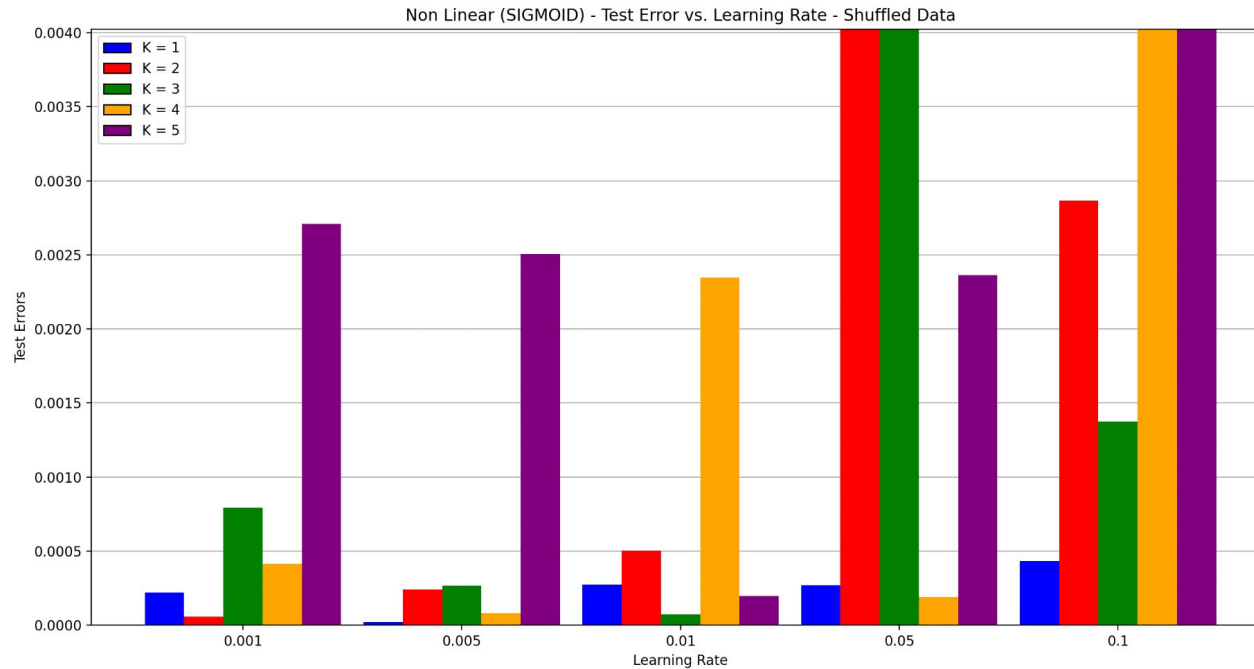
Parámetros:

- Learning rate (0.001, 0.005, 0.01, 0.05, 0.1)
- Online
- Epochs = 100000
- Epsilon = 0
- Función de activación = sigmoide (datos interpolados entre 0 y 1)
- K-Fold: $k = 5$
- Beta = 4

Elección mejor learning rate

Parámetros:

- Online
- Epochs = 100000
- Epsilon = 0
- Función de activación = sigmoide
- K-Fold: k = 5
- Beta = 4





Batch vs. Online

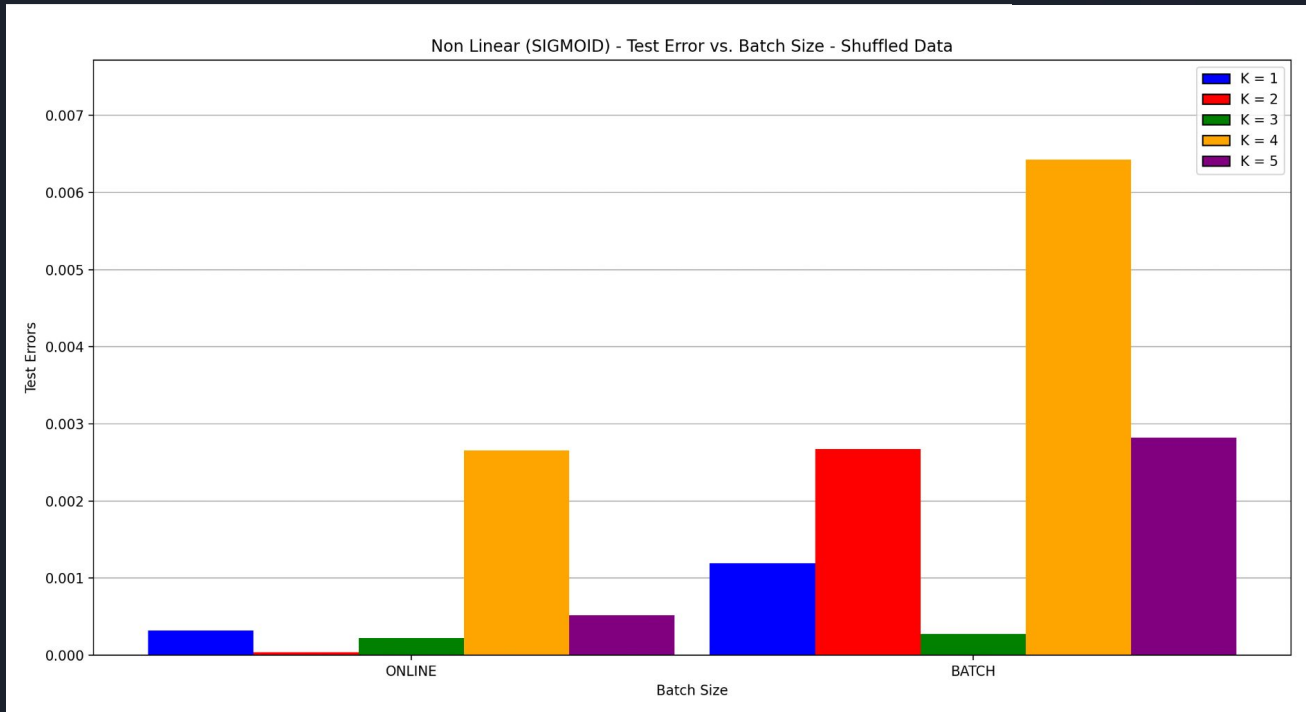
Parámetros:

- Learning rate = 0.01
- Online (batch = 1) - Batch (batch = len(training_set))
- Epochs = 100000
- Epsilon = 0
- Función de activación = sigmoide (datos interpolados entre 0 y 1)
- K-Fold: $k = 5$
- Beta = 4

Batch vs. Online

Parámetros:

- Learning rate = 0.01
- Online (batch = 1) - Batch (batch = len(training_set))
- Epochs = 100000
- Epsilon = 0
- Función de activación = sigmoide
- K-Fold: k = 5
- Beta = 4





Conclusiones

- Capacidad de aprender
- Capacidad de generalización
- Mejor conjunto de entrenamiento
- Listado de los mejores parámetros para este problema:
 - Learning rate = 0.01
 - Online
 - Epochs = 100000
 - Epsilon = 0
 - Función de activación = sigmoide (datos interpolados entre 0 y 1)
 - K-Fold: k = 5
 - Beta = 4




Ejercicio 3




Ejercicio 3A

Elección de Beta




Se probó con $lr = 0,1$ y epsilon 0,001 ver con distintos betas como variaba el error (siempre 2-21 y tan e incremental)

Elección de Learning Rate



Se probó con beta 3 y epsilon 0,001 como variaba el error para distintos lr

Error con las soluciones elegidas



Epochs: 35

Error: 0.00067

Input-Outputs:

$[1,1] = -0.9498$

$[-1,1] = 0.9989$


$[1,-1] = 0.9987$

$[-1,-1] = -0.9869$



EJERCICIO 3B

Errores en la función de paridad



Split 70% train -30% test

LR = 0,1

Beta = 0.8

Epsilon = 0.01

Max Epochs = 10k

Método Online


Parity(6) = 0.8581

Parity(7) = 0.5

Parity(9) = 0.8413


Errores en la función de paridad duplicando el training set

Sin ausencias en el testing set




Final error: 0.0099
Final test error: 0.01246

Con ausencias en el testing set



Final error: 0.0099
Final test error: 0.2019

Si extendemos el dataset 10 veces más...



Split 70% train -30% test

LR = 0,1

Beta = 0.8

Epsilon = 0.01


Max Epochs = 10k

Método Online



Ejercicio 3C


Betas




- Learning Rate = 0.1
- Online
- Epochs = 20000
- Epsilon = 0.5
- Neurons per Layer = [35, 10, 10]
- Expansion = 3
- Split = 0.8

Elección mejor learning rate


Goldilocks approved!



$\alpha = 0.75$
line
chs = 20000
ilon = 0.5
urons per Layer = [35, 10, 10]
ansion = 3




Elección estructura de la red




- Beta = 0.75
- Online
- Epochs = 20000
- Epsilon = 0.5
- Learning Rate = 0.1
- Expansion = 3
- Split = 0.8

Batch vs. Online




- Beta = 0.75
- Epochs = 20000
- Epsilon = 0.5
- Learning Rate = 0.1
- Expansion = 3
- Split = 0.8

Y si agregamos ruido?



- Beta = 0.75
- Batch
- Epochs = 20000
- Epsilon = 0.5
- Learning Rate = 0.1
- Expansion = 3
- Split = 0.8



Tampoco seamos malos...

```
[[0 1 0 1 0]
 [0 0 0 0 0]
 [0 0 1 0 0]
 [1 0 0 1 0]
 [1 0 0 1 0]
 [1 0 0 0 1]
 [1 1 0 1 1]]
```

output:

3


```
[[1 0 1 0 0]
 [0 1 0 0 0]
 [0 0 1 1 0]
 [0 0 0 0 0]
 [0 1 1 0 0]
 [0 0 0 0 0]
 [0 1 1 1 0]]
```

2

```
[[0 1 1 0 0]
 [1 0 0 0 1]
 [0 1 0 1 1]
 [1 0 0 0 1]
 [1 1 0 0 1]
 [0 0 0 0 1]
 [0 1 1 1 1]]
```

0

Achiquemos un poquito entonces...



- Beta = 0.75
- Batch
- Epochs = 20000
- Epsilon = 0.5
- Learning Rate = 0.1
- Expansion = 3
- Split = 0.8



Conclusiones

Ejercicio 1:

- Vemos que el perceptrón escalón es únicamente capaz de aprender funciones linealmente separables

Ejercicio 2:

- El conjunto de datos determina la función de activación necesaria para resolver el problema
- El ordenamiento de los datos y la separación de los mismos son cruciales para la capacidad de generalización del perceptrón
- La cantidad límite de épocas es importante para evitar tener problemas de underfitting

Ejercicio 3:

- El perceptrón multicapa logra reconocer funciones no linealmente separables
- El learning rate debe ser adecuado para no tardar mucho más de lo necesario pero que también logre encontrar el mínimo global
- Es importante separar bien entre testing y training para que no haya underfitting ni overfitting